


DISCIPLINA

Introdução à **Inteligência Artificial e** **Aprendizado de Máquina**

Módulo: Fundamentos de Classificação

Profa. Dra. Denise Tsunoda



Regressão → Classificação

Até agora

Previmos **valores numéricos**.

(Ex: Preço, Consumo, Tempo)

Agora

Vamos prever **categorias**.

(Ex: **Compra ou Não compra**)

O que é Classificação?

Técnica que atribui uma **categoria** a um objeto com base em suas características.

- **Entrada:** Atributos (idade, renda)
- **Saída:** Classe (Sim/Não)

A Arte de Classificar

Ensinando a máquina a organizar o caos através de padrões e categorias.



Onde usamos?



Medicina

Diagnóstico



Segurança

Fraudes



E-mail

Spam

Tabela Comparativa

Regressão

Classificação

Valor Numérico

Categoria

Preço do Imóvel

Aprovado / Reprovado

Temperatura

Doente / Sadio

Como a máquina decide?



Aprendendo padrões nos dados históricos.



Criando regras lógicas de separação.



Organizando decisões de forma sequencial.

Diversos caminhos para decidir

Não existe apenas um modelo. A IA pode decidir por:



Regras
(Árvores)



Probabilidade
(Logística)



Fronteiras
(SVM)



Proximidade
(KNN)



A Base da GenAI
(ANN)




Regressão Logística

O elo entre os módulos.


Utiliza a curva **Sigmóide** para converter um número qualquer em uma probabilidade entre 0 e 1.

$P > 0.5 \rightarrow \text{Sim}$

$P < 0.5 \rightarrow \text{Não}$



SVM (Fronteiras)



Cria a **fronteira de separação** mais larga possível.


O algoritmo busca a "estrada principal" que divide os grupos com a maior margem de segurança.

KNN (Similaridade)


Baseado em **vizinhança**.

O modelo olha para os casos históricos mais parecidos e atribui a classe que for maioria entre eles.

“Diga-me com quem andas e eu direi quem você é.”



🧠 Redes Neurais (ANN)



Inspiradas no cérebro, são o **motor da IA Generativa**.

● **Camadas:** Entrada → Ocultas → Saída.

● **Pesos:** Aprendem a importância de cada padrão.


Fundamento de LLMs e Geradores de Imagem.

Exemplo: Reconhecimento


O Fluxo da Decisão

A Rede Neural quebra uma imagem em milhares de **pixels**.


Cada camada identifica algo: bordas → formas → orelhas → **ZEBRA!**




Exemplo: Reconhecimento



Exemplo: Reconhecimento



Exemplo: Reconhecimento




Ex


ento

Pooling: reduz o tamanho dos dados mantendo o que é mais relevante.

Isso torna o processamento mais eficiente e **ajuda a rede a reconhecer o objeto** mesmo que ele esteja um pouco deslocado na imagem.




Exemplo: Reconhecimento




Exemplo: Reconh

Na etapa de **classificação**, as camadas totalmente conectadas analisam essas informações e calculam a probabilidade da imagem pertencer a cada classe.



Exemplo: Reconhecimento

No final, a função **Softmax** transforma os resultados em probabilidades.



RESUMO: A CNN primeiro extrai características da imagem e depois usa essas características para classificar o objeto.

Resumo dos Métodos

Método	Intuição	Interpretação
Árvore	Perguntas lógicas	ALTA
SVM	Fronteiras/Margens	Baixa
KNN	Semelhança	Média
Redes Neurais	Cérebro/Padrões	MUITO BAIXA


A escolha do método define o sucesso da sua IA.

Na IA Generativa, a complexidade é o caminho para a criatividade.

Árvore de Decisão

Modelo que toma decisões por meio de perguntas sequenciais:

- 🌳 **Nó:** Pergunta
- 🌳 **Ramo:** Resposta
- 🌳 **Folha:** Decisão final



Exemplo: Vai comprar?

Idade < 30?

SIM →
Estudante?

NÃO → Não
compra

Se Estudante = COMPRA

**// Não é sobre construir a árvore —
é sobre interpretá-la.**

Qual variável aparece primeiro? Faz sentido?

Dados → Decisão

Linhas

Cada linha é um **Caso** histórico.


Colunas

Cada coluna é uma
Característica.

Ferramenta: Orange


orange
DATA MINING

- ❖ É software livre (open source)
- ❖ Distribuído sob licença **GPL** (gratuito para uso e modificação)
- ❖ Disponível para **Windows, Mac e Linux**
- ❖ Não exige pagamento, licença institucional ou cadastro




Ferramenta: Orange

- ✦ Totalmente Visual
- ✓ Simples e Intuitivo
- ⚡ Sem programação



Download: Orange



The screenshot shows the 'Download' page of the Orange Data Mining website. The browser address bar displays 'orangedatamining.com/download/'. The website header includes the 'orange DATA MINING' logo, navigation links for 'Screenshots', 'Download', 'Blog', 'Docs', 'Workshops', and 'Donate', and a search bar. A large purple banner with the text 'Suggested Download' and a button 'Orange 3.40.0 for Windows' is featured. To the right of the banner is a cartoon orange character with glasses. Below the banner, the 'Windows' section lists two options: 'Standalone installer (default)' with a download link for 'Orange3-3.40.0-x86_64.exe' and a note that it can be used without administrative privileges, and 'Portable Orange' with a download link for 'Orange3-3.40.0.zip' and a note that no installation is needed. The 'macOS' section lists 'Orange for Apple silicon' with a download link for 'Orange3-3.40.0-Python3.12.10-arm64.dmg'. A callout box titled 'Installing add-ons' explains that additional features can be added by installing add-ons and that an add-on manager is available in the Options menu. Decorative icons for various data mining functions are scattered around the callout box.

orangedatamining.com/download/

orange
DATA MINING

Screenshots Download Blog Docs Workshops Donate Search

Suggested Download

Orange 3.40.0 for Windows

Windows

Standalone installer (default)

📄 [Orange3-3.40.0-x86_64.exe](#)
Can be used without administrative privileges.

Portable Orange

📄 [Orange3-3.40.0.zip](#)
No installation needed. Just extract the archive and open the shortcut in the extracted folder.

macOS

Orange for Apple silicon

📄 [Orange3-3.40.0-Python3.12.10-arm64.dmg](#)

Installing add-ons

Additional features can be added to Orange by installing add-ons. You can find add-on manager in Options menu.

<https://orangedatamining.com/download/>

Orange: suporte

✓ YouTube: <https://www.youtube.com/channel/UCIKKWBe2SCAEyv7ZNGhle4g>



Fruitful & Fun



Orange Data Mining

@OrangeDataMining • 49,2 mil inscritos • 107 vídeos

Video tutorials for Orange data mining suite. Explanation of popular data mining algorithms. ...mais

orangedatamining.com

Inscriver-se

[Início](#) [Vídeos](#) [Shorts](#) [Cursos](#) [Playlists](#) [Posts](#) [Pesquisar](#)



Orange Workflows


78.409 visualizações • há 2 anos

In this video, you will learn about the first steps when working with Orange data mining program - how to open and navigate it, add widgets to the canvas, create simple workflows, add data from the existing datasets.


This video is a part of Introduction to Data Science video series that dives into machine learning, visual analytics, and joys of ...

LEIA MAIS

Interface do Orange



Interface do Orange



Foco em carregar, conectar e visualizar.

Passo 1: Carregar

The screenshot shows the Orange data mining software interface. On the left, the 'Visualize' widget is selected, displaying a grid of visualization options including Tree Viewer, Box Plot, Violin Plot, Distributions, Scatter Plot, Line Plot, Bar Plot, Sieve Diagram, Mosaic Display, FreeViz, Linear Projection, Radviz, Heat Map, Venn Diagram, Silhouette Plot, and Pythagorean Tree. The 'Tree Viewer' is currently active. In the center, a 'File' widget is being configured. The 'Source' is set to 'File: Classificação\Classificacao.csv'. The 'File Type' is 'Comma-separated values (*.csv *.csv.gz *.gz *.csv.bz2 *.bz2 *.csv.xz *.xz)'. The 'Info' section shows '12 instances', '5 features (no missing values)', 'Data has no target variable.', and '0 meta attributes'. The 'Columns' table is displayed below the info section.

	Name	Type	Role	Values
1	Idade	Ⓢ categorical	feature	Adulto, Idoso, Jovem
2	Renda	Ⓢ categorical	feature	Alta, Baixa, Media
3	Estudante	Ⓢ categorical	feature	Nao, Sim
4	Historico Credito	Ⓢ categorical	feature	Bom, Ruim
5	Compra	Ⓢ categorical	feature	Nao, Sim

Buttons at the bottom of the File widget include 'Reset', 'Apply', and 'Browse documentation datasets'. The bottom status bar shows '12' instances.

Abra seu dataset e visualize a tabela para conferir se as categorias estão corretas.

Passo 2: Construir

The screenshot displays the Orange3 data mining software interface. On the left, the 'Widget' pane shows a list of available widgets categorized into Data, Transform, Visualize, and Model. The 'Model' category is selected, and the 'Tree' widget is highlighted. In the center, a workflow is shown with a 'File' widget connected to a 'Tree' widget via a 'Data' connection. The 'Tree' widget has a red 'X' icon above it, indicating an error. On the right, the 'Tree - Orange' settings dialog is open, showing the following parameters:

- Name: Tree
- Parameters:
 - ☒ Induce binary tree
 - ☒ Min. number of instances in leaves: 2
 - ☒ Do not split subsets smaller than: 5
 - ☒ Limit the maximal tree depth to: 100
- Classification:
 - ☒ Stop when majority reaches [%]: 95
- ☒ Apply Automatically

At the bottom of the dialog, a status bar indicates 'Data has no ta...' (likely 'Data has no target').

Selecione o modelo "**Tree**" e conecte-o ao seu conjunto de dados.

Passo 2A: O que ocorreu?

The screenshot shows the Orange data mining software interface. On the left, the 'Visualize' widget category is selected, displaying various visualization options like Tree Viewer, Box Plot, Violin Plot, Distributions, Scatter Plot, Line Plot, Bar Plot, Sieve Diagram, Mosaic Display, FreeViz, Linear Projection, Radviz, Heat Map, Venn Diagram, Silhouette Plot, and Pythagorean Tree. Below this, the 'File' widget is described: 'Read data from an input file or network and send a data table to the output.' A 'more...' link is also present.

In the center, a 'File' widget icon is shown with a bracket indicating its connection to the configuration window on the right.

The 'File - Orange' configuration window is open, showing the following details:

- Source:** File: C:\Classificação\Classificacao.csv (with a 'Reload' button)
- File Type:** Comma-separated values (*.csv *.csv.gz *.gz *.csv.bz2 *.bz2 *.csv.xz *.xz)
- Info:** 12 instances, 5 features (no missing values), Data has no target variable, 0 meta attributes
- Columns (Double click to edit):**


	Name	Type	Role	Values
1	Idade	Ⓢ categorical	feature	Adulto, Idoso, Jovem
2	Renda	Ⓢ categorical	feature	Alta, Baixa
3	Estudante	Ⓢ categorical	feature	Sim, Não
4	Historico Credito	Ⓢ categorical	feature	Sim, Não
5	Compra	Ⓢ categorical	target	Sim, Não

A large green arrow points to the 'Compra' row in the columns table, highlighting it as the target variable.


At the bottom of the configuration window, there are 'Reset' and 'Apply' buttons, and a 'Browse documentation datasets' link.

Passo 3: Visualizar

Insira o TreeViewer e conecte-o à árvore.



Passo 3: Visualizar



O que observar?

Variável Raiz


Qual é a mais importante?

Caminhos


Como ela decide?

Padrões

Há lógica clara?



Avaliar



Avaliar

The screenshot displays the Orange data mining software interface. The main workspace shows a workflow with the following components and connections:

- File** widget connected to **Tree** widget via a **Data** connection.
- Tree** widget connected to **Tree Viewer** widget via a **Model → Tree** connection.
- Tree** widget connected to **Test and Score** widget via a **Data** connection.
- Tree** widget connected to **Test and Score** widget via a **Learner** connection.

The left sidebar contains a widget palette with the following categories and widgets:

- Data**: File, Table, etc.
- Transform**: Filter, etc.
- Visualize**: Scatter Plot, etc.
- Model**: Decision Tree, etc.
- Evaluate**: Test and Score, Predictions, Feature as Predictor, Confusion Matrix, ROC Analysis, Performance Curve, Calibration Plot, Permutation Plot.
- Parameter**: Parameter widget.

Below the widget palette, there is a section for widget descriptions and links to [workflow examples](#), [YouTube tutorials](#), and the [welcome screen](#).

The bottom right corner displays the **Evaluation results for target (None, show average over classes)** table:

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.743	0.667	0.648	0.815	0.667	0.488

Vamos olhar cada um...

■ AUC (0.743)

👉 Capacidade do modelo separar as classes

- ▶ 1.0 = perfeito
- ▶ 0.5 = aleatório
- ▶ ✓ 0.743 → razoável

■ CA – Accuracy (0.667)

👉 % de acertos totais

- ▶ ✓ 66,7% dos casos corretos

■ F1 (0.648)

👉 Equilíbrio entre precisão e recall

- ▶ bom quando há classes desbalanceadas
- ▶ ✓ valor intermediário

■ Precision (0.815)

👉 Quando o modelo diz “Sim”, ele acerta?

- ▶ ✓ 81,5% das vezes está correto
- ▶ 👉 “confiança” da previsão positiva

■ Recall (0.667)

👉 O modelo encontra todos os “Sim”?


- ▶ ✓ encontra ~66,7%
- ▶ 👉 capacidade de “capturar” os positivos

■ MCC (0.488)

👉 Métrica mais robusta (leva tudo em conta)

- ▶ varia de -1 a +1
- ▶ 0 = aleatório
- ▶ ✓ 0.488 → desempenho moderado

Avaliar



		Predicted		
		Nao	Sim	Σ
Nao		5	0	5
Sim		4	3	7
Σ		9	3	12

**A IA decide com dados,
mas o valor é definido pelo
contexto.**


Pergunta: É suficiente saber a taxa de acerto?

Qualidade do Modelo


É suficiente saber a taxa de acerto?

É suficiente saber a taxa de acerto para avaliar um modelo?

Sim



Não



menti.com
4407 6300

Waiting for participants

MÉTRICAS DE CLASSIFICAÇÃO

Matriz de Confusão

A anatomia por trás da avaliação de modelos de IA.

Além da Acurácia

A Matriz de Confusão é uma tabela que mostra a **performance real** de um modelo.

Ela compara os **Valores Reais** com os **Valores Previstos** pelo algoritmo.



Estrutura da Matriz

PREVISÃO DO MODELO	
REALIDADE	
	Verdadeiro Positivo (VP)
	Falso Positivo (FP)
	Falso Negativo (FN)
	Verdadeiro Negativo (VN)

Os Quadrantes do Sucesso

Verdadeiro Positivo (VP)

O modelo previu **SIM** e na realidade era **SIM**.

Ex: Detectou a doença corretamente.

Verdadeiro Negativo (VN)

O modelo previu **NÃO** e na realidade era **NÃO**.

Ex: Identificou o paciente saudável.

Falso Positivo (Tipo I)



O modelo previu **SIM**, mas na realidade era **NÃO**.

"O Alarme Falso"

Ex: O sistema diz que o e-mail é SPAM, mas é uma mensagem importante do seu chefe.

Falso Negativo (Tipo II)



O modelo previu **NÃO**, mas na realidade era **SIM**.

"A Omissão Perigosa"

Ex: O modelo diz que o paciente está sadio, mas ele está realmente doente.

Precisão (Precision)

Foco na **Qualidade**: Quando o modelo diz que é SIM, o quanto podemos confiar?

$$\text{Precisão} = \frac{VP}{VP+FP}$$

Ideal para situações onde **Falsos Positivos** são caros (ex: condenações judiciais).

Recall (Sensibilidade)

Foco na **Abrangência**: De todos os casos reais de SIM, quantos o modelo conseguiu capturar?

$$\text{Recall} = \frac{VP}{VP+FN}$$

Crítico para situações onde **Falsos Negativos** são perigosos (ex: diagnósticos de doenças).

F1-Score: O Equilíbrio

A média harmônica entre Precisão e Recall. Uma única métrica para representar o **balanço** entre as duas.

$$\text{F1-Score} = 2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}$$

Melhor métrica para avaliar datasets **desbalanceados**.

Qual métrica importa?

Contexto Médico

Priorizamos o **Recall**. Não queremos deixar nenhum doente sem tratamento.

Contexto Bancário

Priorizamos a **Precisão**. Não queremos bloquear o cartão de um cliente legítimo por engano.

Resumo Analítico

Acurácia

Taxa geral de acerto.

Precisão

Evita alarmes falsos.

Recall

Não deixa nada passar.

F1-Score

O equilíbrio ideal.

EXEMPLO

Alta Acurácia Enganosa

Por que 95% de acerto pode ser um desastre.

Cenário: Doença Rara

Imagine que precisamos prever se um paciente tem uma doença rara:



Total: 100 pacientes



95 NÃO têm a doença



5 TÊM a doença



O Modelo "Burro"



Lógica do Modelo

Ele é programado para sempre responder:

"NÃO tem a doença"

O robô ignora os dados e escolhe a classe majoritária para nunca arriscar.

Mapeando os Resultados

Grupo Real	Previsão do Robô	Resultado
95 Saudáveis	"NÃO tem doença"	95 Corretos
5 Doentes	"NÃO tem doença"	0 Corretos

| Cálculo da Acurácia

$$\text{Acurácia} = \frac{95}{100} = 95 \%$$



RESULTADO ALTÍSSIMO!

| Mas... e os doentes?



Recall (Doentes)

0%



Métrica F1

PÉSSIMO

| O Problema Real

O modelo falhou em identificar 100% dos pacientes que realmente precisavam de ajuda.

 **Interpretação:** O modelo parece bom estatisticamente, mas é **inútil** na prática médica.

| Conclusão Crítica

-  **Dataset Desbalanceado:** Quando uma classe domina a outra.
-  **Acurácia Alta $\neq$ Modelo Bom:** Ela esconde falhas graves em classes minoritárias.
-  **Solução:** Use Precision, Recall e F1-Score para uma visão real.

"Alta acurácia não significa um bom modelo."

Lembre-se do contexto e do risco real.

Qualidade do Modelo

Não basta acertar — precisamos
entender COMO o modelo acerta e
erra.

Atenção: Limitações

- ⚠ Dados ruins geram modelos ruins.
- ⚠ Árvores são **simplificações** da realidade.
- ⚠ Não é uma verdade absoluta.

Atividade Prática

Dataset

Todos usam os
mesmos

Gerar

Criar a árvore

Interpretar

Analisar a lógica

Atividade 1: Interpretando a árvore

🎯 Objetivo

Compreender como o modelo toma decisões sequenciais.

⚙️ Tarefa (Orange)

- Carregar o dataset
- Construir a árvore de decisão
- Observar a estrutura

✍️ RESPONDER NO MOODLE

- ? Qual variável aparece na raiz da árvore?
- ? Qual caminho leva à decisão “Sim”?
- ? O modelo faz sentido no contexto?

Dica: Cada caminho representa uma regra de decisão.

Qual variável parece mais importante? Por quê?

Atividade 2: Avaliando o modelo

Objetivo

Analisar criticamente o desempenho do modelo.

Tarefa (Orange)

- Conectar o widget **Test & Score**
- Observar as métricas geradas

RESPONDER NO MOODLE

- ? Qual é a accuracy (taxa de acerto)?
- ? A accuracy é suficiente para avaliar o modelo?
- ? Você confiaria nesse modelo?

 **Alta accuracy $\neq$ Bom modelo**

Atividade 3: O Problema Real

**Dados Desbalanceados:
carregar o outro dataset**

95%

Casos:
"NÃO"

5%

Casos: "SIM"

Cenário: Um modelo que sempre responde
"NÃO".

RESPONDER NO MOODLE

- ? Qual é a acurácia desse modelo?
- ? Esse modelo é útil?
- ? O que ele falha em fazer?
- ? Qual métrica revela esse erro?

**Reflexão: Você usaria esse modelo em um
hospital?**

Organização da Atividade

Grupos

Até 5 alunos por
equipe.
Todos os grupos
realizam todas as
atividades



Tempo

30 a 35 minutos
para as 3 atividades.



Entrega

Respostas
individuais no
Moodle.

Atenção: Grupos serão sorteados para apresentar suas interpretações!

| Conclusão e Fechamento

- ✓ Modelos aprendem padrões, não verdades absolutas.
- ✓ As métricas precisam de **interpretação humana**.
- ✓ O contexto do problema define se o modelo é útil ou inútil.

**"Um modelo pode parecer bom —
e ainda assim ser completamente inútil."**

Modelos não entendem o problema — eles apenas identificam padrões nos dados.

| Apresentação

3'

MINUTOS POR GRUPO

Foco total na interpretação dos resultados.



**Classificação não é sobre
algoritmos — é sobre decisão.**

**O modelo aprende com dados,
mas a interpretação é
humana.**

Obrigada pessoal e até a
próxima!