

Desvendando Afinidades: Mineração de Regras de Associação

Profa Dra Denise Tsunoda

Nosso Roteiro de Hoje

Teoria e Fundamentos

- Associação no Ecossistema ML
- A Lenda da Cerveja e Fraldas
- As Métricas (S, C, Lift)
- A Poda do Apriori

Laboratório e Dinâmica

- Passo a Passo no Excel
- Divisão em 18 Grupos
- Apresentação das 6 Bases
- Debate de Insights Críticos




Parte 1: Posicionamento Estratégico

Onde estamos no Ecossistema?

O Machine Learning divide-se em grandes tarefas. A **Associação** pertence ao grupo:

**Aprendizado NÃO
Supervisionado**

Aqui, não temos um "alvo" definido (label). O algoritmo busca o padrão oculto.




Posicionamento no Ecossistema

A tarefa de associação pertence a uma categoria específica da Inteligência Artificial:

Aprendizado NÃO Supervisionado

Diferente de Classificação e Regressão, não buscamos uma "resposta certa" histórica, mas sim a estrutura inerente aos dados.



Associação vs. Outras Tarefas

Tarefa	Pergunta Fundamental	Natureza
Classificação	"Este cliente vai cancelar?"	Supervisionado
Regressão	"Qual será o faturamento em R\$?"	Supervisionado
Clustering	"Quais clientes são parecidos?"	Não Supervisionado
Associação	"Quais itens são comprados juntos?"	Não Supervisionado

Recado da Profa.

Recado da Profa.

A diferença chave: o Agrupamento (Clustering) busca 'perfis de pessoas'. A Associação busca 'conexões entre objetos'.

Market Basket Analysis (MBA)

Market Basket Example



Análise do Cesto de Compras

É a aplicação mais clássica da tarefa de associação. O objetivo é entender o comportamento de consumo baseado em **coocorrência**.

"Quem comprou Pão, também comprou Manteiga?"

Market Basket Example



- ? Where should detergents be placed in the Store to maximize their sales?
- ? Are window cleaning products purchased when detergents and orange juice are bought together?
- ? Is soda typically purchased with bananas? Does the brand of soda make a difference?
- ? How are the demographics of the neighborhood affecting what customers are buying?

Market Basket Analysis

O que vai com o quê no carrinho de compras?

A análise da cesta de compras busca mapear a afinidade natural entre produtos para otimizar layout e promoções.



| Aplicação: Recomendações Digitais

Amazon e Streaming

"Clientes que levaram X também levaram Y".

A descoberta das regras é off-line (pesada);
a aplicação é on-line (leve).



Aplicação: Saúde e Diagnóstico



Prontuários Eletrônicos

Identificação de coocorrência de sintomas e resultados de exames para disparar alertas preventivos.

*{Pressão Alta, Diabetes} ⇒
Risco Renal*

| A Estrutura da Regra

X: Antecedente Y: Consequente

$$X \Rightarrow Y$$

"SE X, ENTÃO Y"

X: Antecedente

O conjunto gatilho.

Y: Consequente

O conjunto associado.

Cuidado: Associação $\neq$ Causa

REGRA VITAL:

A implicação significa apenas coocorrência estatística.

Exemplo: Protetor solar e sorvete aparecem juntos. O protetor não causa o desejo por sorvete; o causador real oculto é o calor do verão.

Recado da Profa.

O algoritmo entrega o número, você entrega o significado estratégico.



Parte 2: A Matemática das Regras

PPGCD | GESTÃO DA INFORMAÇÃO

As Três Réguaas da Associação

Entendendo Suporte, Confiança e Lift em Alto Nível

Profa. Dra. Denise Tsunoda

Por que precisamos de métricas?

Em uma base de dados real, existem milhões de regras possíveis. As métricas servem como **filtros de relevância** para separar o ruído do conhecimento estratégico.

1. Suporte: O Filtro de Popularidade

O Suporte responde à pergunta:

"Quão comum é esse padrão na base total?"



Mede a **frequência** estatística.



Serve para descartar **regras raras** ou irrelevantes.



Foca no que atinge a massa de dados.

$$\text{Suporte} = \frac{\text{Ocorrências de (X e Y)}}{\text{Total de Transações (N)}}$$

Ex: "Este combo aparece em 10% das vendas totais?"

■ Métrica 1: Suporte (Support)

Quão frequente é a combinação na base total de N transações?

$$\text{Support} = \frac{\text{Count} (X \cap Y)}{N}$$

Usamos o suporte para descartar ruídos e focar no que é relevante.

O símbolo $\cap$ (**Interseção**) indica itens que aparecem **juntos**.

Exemplo: Suporte de {Café ∩ Pão}

Se em 100 vendas, Pão e Café aparecem juntos em 25 delas:

$$25 / 100 = 0,25 \text{ (25\%)}$$

Utilizamos o Suporte para eliminar o que é **ruído** ou raro demais para o negócio.

2. Confiança: O Filtro de Fidelidade

A Confiança responde à pergunta:

"Se o antecedente ocorreu, qual a chance do consequente estar lá?"

 Mede a **força da conexão** entre itens.

 É uma probabilidade condicional.

 Define a **direção** da regra ($X \rightarrow Y$).

$$\text{Confiança} = \frac{\text{Ocorrências de (X e Y)}}{\text{Ocorrências apenas de X}}$$

Ex: "Das vezes que comprou café, em 80% levou açúcar."

■ Métrica 2: Confiança (Confidence)

Se X aconteceu, qual a probabilidade condicional de Y estar presente?

$$\text{Confidence} = \frac{\text{Count} (X \cap Y)}{\text{Count} (X)}$$

Denominador vital: Dividimos apenas pelas vezes que o Antecedente apareceu!

OU SEJA: O denominador é apenas a contagem do ANTECEDENTE!

A Armadilha da Confiança

Uma confiança de 90% parece ótima? Talvez não.

Se o item Y (ex: Pão) aparece em 90% das transações sozinho, qualquer antecedente terá confiança alta para ele, mesmo que não haja afinidade real.

Para isso, precisamos do LIFT.

3. Lift: O Filtro de Interesse

O Lift responde à pergunta:

"Essa regra traz conhecimento novo ou é apenas óbvia?"

- 💡 Mede o **ganho de informação**.
- ⚖️ Remove o efeito de itens muito populares.
- 💎 É a métrica mais valiosa para o **negócio**.

$$\text{Lift} = \frac{\text{Confiança da Regra}}{\text{Suporte Individual do Consequente}}$$

Ex: "Comprar X aumenta em 3x a chance de comprar Y."

Métrica 3: Lift (Interesse)

O Lift remove o efeito da popularidade dos itens:

$$\text{Lift} = \frac{\text{Conf} (X \Rightarrow Y)}{\text{Supp} (Y)}$$

> 1: Útil

= 1: Acaso

< 1: Afasta


Interpretando o LIFT

LIFT > 1: Associação Positiva. X atrai Y. (Útil para o negócio)

LIFT = 1: Independência. É o mesmo que jogar uma moeda.

LIFT < 1: Associação Negativa. X "afasta" Y.

Apriori Algorithm Metrics Hierarchy



Resumo Comparativo

Métrica	Foco Principal	Valor de Gestão
Suporte	Frequência Global	Define se a regra tem escala suficiente.
Confiança	Probabilidade Condicional	Define a confiabilidade da previsão.
Lift	Interesse Estatístico	Define se a regra é estratégica ou acaso.

Lembrem-se: Uma confiança alta com um Lift de 1.0 significa que o item seria comprado de qualquer jeito. O gestor busca LIFTs altos!



Parte 3: O Algoritmo Apriori

O Princípio da Poda (Pruning)

Propriedade Anti-monotônica:

"Se um itemset é infrequente, todos os seus superconjuntos também serão infrequentes."

Se 'Adoçante' apareceu só 1 vez (abaixo do MinSup), não faz sentido testar $\{\text{Adoçante} \cap \text{Café}\}$.

Recado da Profa.
RECADO DA PROFA.

Esse "truque" é o que permite processar milhares de itens sem que o computador trave. Cortamos os galhos podres logo na raiz.

Passo 1: Conjunto L1

Identificamos o suporte de cada item sozinho na base:

Item	Suporte	Decisão (MinSup=0.4)
Café	0.8	MANTIDO
Pão	0.7	MANTIDO
Leite	0.5	MANTIDO
Vassoura	0.1	PODADO (Eliminado)

Passo 2: Gerando Pares (C2)

Combinamos apenas os itens que sobreviveram a L1:

- {Café, Pão}
- {Café, Leite}
- {Pão, Leite}

Contamos o suporte conjunto desses pares na base de dados.

Passo Final: Gerando Regras

Para cada par frequente (ex: {Café, Pão}), testamos as duas direções:

Regra 1: Café $\Rightarrow$ Pão

Calculamos Confiança e Lift.

Regra 2: Pão $\Rightarrow$ Café


Os resultados serão diferentes!

O Desafio da Explosão

Com apenas 4 itens (A, B, C, D), podemos gerar mais de 50 regras potenciais.

Dado d itens, há 2^d possíveis itemsets. Em um mercado com 10.000 itens, o cálculo por força bruta travaria o computador.

O Desafio da Explosão



O "Apriori Trick"

Propriedade Anti-monotônica:

"Se um itemset é infrequente, todos os seus superconjuntos também serão infrequentes."

Ação: O algoritmo corta (poda) ramos inteiros da árvore de busca precocemente.





Parte 4: Execução no Excel

GUIA PRÁTICO PASSO A PASSO

Calculando Regras de Associação no Excel

Aprenda a mecânica do Apriori na prática.

RECAP DO EXCEL

Olá! Para os que não puderam vir ou preferem estudar sozinhos: o Excel é nossa melhor ferramenta para "abrir a caixa preta" do algoritmo. Vamos transformar transações em números!

1. A Matriz Binária

O primeiro passo é transformar nomes de itens em **0** e **1**.

TID	Café	Pão	Leite	Manteiga
1	1	1	0	0
2	1	0	1	1
3	0	1	1	0
4	1	1	1	0

`=SOMA(B2:B5)` → Total de vezes que o item aparece

RECAP DO DA PROFA.

Crie uma coluna para cada produto da sua base. Se o cliente comprou, marque 1. Se não, marque 0. Essa estrutura permite que o Excel "entenda" a coocorrência.

Lógica Excel de Suporte e Confiança

Métrica	Fórmula Excel
Suporte Par AB	=SOMA_Interseção / N_Total
Confiança A $\Rightarrow$ B	=SOMA_Interseção / SOMA_Antecedente_A
Lift A $\Rightarrow$ B	=Célula_Confiança / Suporte_Individual_B

Recado da Profa.
RECADO DA PROFA.

Fiquem atentos: se o Lift der EXATAMENTE 1, a sua regra é puramente baseada no acaso. Como gestores, busquem regras com Lift > 1,2.

2. Cálculo do Suporte Individual

O Suporte diz: "Qual a porcentagem de vezes que este item aparece no total?"

$$\text{Suporte} = \text{Contagem do Item} / \text{Total de Transações (N)}$$

Exemplo: Se o Café apareceu em 3 de 4 vendas:

$$3 / 4 = 0,75 (75\%)$$

RECAP DO DIA

Regra da Poda: Se o seu "Corte de Suporte" for 50%, qualquer item com resultado menor que 0,50 deve ser excluído da análise agora mesmo!

3. Suporte do Conjunto ($A \cap B$)

Para saber quantas vezes dois itens aparecem juntos, use a função **E** no Excel:

```
=SE(E(B2=1; C2=1); 1; 0)
```

Arraste para todas as linhas e some o resultado final.

Resultado Final:
RECAP DO DA PROVA.

A "interseção" na computação para o Excel é apenas verificar se as duas células são iguais a 1 ao mesmo tempo. Se sim, temos um par!

4. Cálculo da Confiança

A Confiança mede: "Das vezes que comprei **A**, qual a chance de ter levado **B**?"

$$\text{Confiança } (A \rightarrow B) = \text{Contagem}(A \cap B) / \text{Contagem}(A)$$

Cuidado: O denominador é apenas a contagem do item que vem antes da seta (Antecedente).

RECAP DA PROVA.

Este é o erro mais comum: errar o denominador. Se a regra é "Pão → Café", divida pelo total de Pão. Se for "Café → Pão", divida pelo total de Café.

5. Cálculo do Lift (O Valor Real)

O Lift remove o efeito de itens que são populares demais (que todo mundo compra de qualquer jeito).

$$\text{Lift} = \text{Confiança}(A \rightarrow B) / \text{Suporte}(B)$$

- **Lift > 1:** A regra é boa (Associação positiva).
- **Lift = 1:** A regra é inútil (Independência).

RECAP DO DIA.

Se o Lift for 1, significa que o cliente compraria o item B com ou sem o item A. A sua estratégia de marketing seria desperdiçada aqui.



Demonstração no Excel

Parte 5: Execução em equipes

Atividade de Laboratório (2h)

| 18 Grupos | 6 Bases

Cada trio de grupos analisará a mesma base, mas buscará **as regras de ouro** de forma independente para confrontar resultados depois.

MinSup: 0,3 (30%) | MinConf: 0,7 (70%)

Base 1: Cafeteria Gourmet

Contexto

O gerente quer combos matinais lucrativos.

Itens: {Café, Pão de Queijo, Bolo, Suco, Sanduíche}

Desafio

Descobrir se a venda de suco é um antecedente forte para sanduíches ou se é apenas um item isolado.

| Base 2: Streaming CinePlus

Contexto

Melhorar o algoritmo de recomendação lateral.

Itens: {Documentário, Ação, Comédia, Terror, Ficção}

Desafio

Identificar se quem assiste Terror tem Lift elevado para Ficção, sugerindo um subgênero "Sci-Fi Horror".

| Base 3: Farmácia Vida

Contexto

Padrões de autocuidado preventivo.

Itens: {Antigripal, Vitamina C, Máscara, Termômetro, Analgésico}

Desafio

Provar que a compra de termômetros é o "gatilho" (antecedente) para kits de medicação complexos.

Base 4: E-commerce Gamer

Contexto

Estoque casada e bundles promocionais.

Itens: {Mouse, Teclado, Headset, Webcam, Monitor}

Desafio

Verificar se a Webcam é um item independente ou se sua venda depende de um par prévio de periféricos.

Base 5: Pet Shop Amigo Fiel

Contexto

Cupons de fidelidade no checkout.

Itens: {Ração Cão, Ração Gato, Brinquedo, Petisco, Antipulga}

Desafio

Identificar qual mimos (petiscos/brinquedos) têm maior Lift quando a Ração é o antecedente.

| Base 6: Biblioteca de Tecnologia

Contexto

Reorganização das estantes físicas.

Itens: {Livro Python, Livro Estatística, Livro SQL, Livro BI, Livro Gestão}

Desafio

Validar se {Python & Estatística} $\Rightarrow$ {SQL} justifica uma seção exclusiva de "Ciência de Dados".



Parte 6: Análise Crítica e Ética



Associação NÃO é Causalidade

Cuidado Metodológico


A regra {Cerveja} $\Rightarrow$ {Fralda} não significa que a cerveja causa a compra da fralda. Elas apenas coocorrem.

O papel do especialista é interpretar o fenômeno social/comercial por trás do número.

| Análise Crítica: Ética e Viés

Algoritmos de associação podem reforçar estereótipos ou criar "bolhas de filtro" (sugerir sempre o mesmo)

Como gestores, devemos auditar as regras para evitar recomendações discriminatórias.





Atividades em Grupo

Mão na massa: 193 mentes trabalhando!



Dúvidas e Próximos Passos

Preparem-se para o debate entre os
grupos!

Dra Denise Tsunoda