


Análise de Agrupamento (Clustering)

Fundamentos, Normalização e o Algoritmo K-Means

Profa. Dra. Denise Tsunoda



O Propósito do Agrupamento


Definição Principal: Divisão de um conjunto de dados em subgrupos (clusters) baseando-se em medidas de similaridade.

Características do Padrão:

- **Homogeneidade Interna:** Elementos dentro do mesmo grupo devem ser o mais parecidos possível entre si.
- **Heterogeneidade Externa:** Elementos de grupos diferentes devem ser o mais distintos possível entre si.

Aplicações de Alto Nível:

- Segmentação de clientes, compressão de imagens, taxonomia biológica
- Detecção de comportamentos anômalos



Posicionamento no Ecossistema ML

Natureza da Tarefa: Aprendizado Não Supervisionado (Unsupervised Learning).

A Ausência de Alvos: Não existe variável alvo predefinida (Y ou rótulo/label).

Diferença Chave:

- Classificação (Supervisionado): Aprende com exemplos rotulados para prever classes conhecidas.

Ex: 'Este cliente vai cancelar?'



- Agrupamento (Não Supervisionado): Vasculha os dados para extrair estrutura oculta.

Ex: 'Quais clientes são naturalmente parecidos?'

Classification

VS

Clustering



Risk classification for the loan payees on the basis of customer salary

Associação vs. Agrupamento

Uma Confusão Comum: Ambas são não supervisionadas, mas operam em dimensões lógicas diferentes.

Atenção:


- Mineração de Associação: Busca conexões e regras de coocorrência entre objetos.

Ex: 'Quem compra vinho, leva queijo'

- Análise de Agrupamento: Busca mapear perfis e distâncias entre entidades.

Ex: 'Quem são os clientes de alto poder aquisitivo e baixa fidelidade?'


CLASSICAL MACHINE LEARNING



Clusterizar de forma manual um grande conjunto de dados pode custar muito esforço, tempo, dinheiro etc.

Alternativa: utilizar métodos de Clusterização automática para encontrar agrupamentos nos dados.


Exemplo da aplicação de Clusterização



- ✓ Segmentação de clientes
- ✓ Segmentação de produtos
- ✓ Detecção de anomalias
- ✓

Agrupamento: critérios

- Dado um conjunto de objetos, colocar os objetos em grupos baseados na similaridade entre eles
 - Utilizado para encontrar padrões inesperados nos dados
 - Inerentemente é um problema não definido claramente
- Como agrupar os animais abaixo?





Agrupamento

- Dado um conjunto de objetos, colocar os objetos em grupos baseados na similaridade entre eles

- Utilizado para encontrar padrões inesperados nos dados

- Inerentemente é um problema não definido claramente

- Como agrupar os animais abaixo?




Com bico? Sem bico?

Agrupamento

- Dado um conjunto de objetos, colocar os objetos em grupos baseados na similaridade entre eles
- Utilizado para encontrar padrões inesperados nos dados
- Inerentemente é um problema não definido claramente

- Como agrupar os animais abaixo?



Água? Terra?


Agrupamento

- Dado um conjunto de objetos, colocar os objetos em grupos baseados na similaridade entre eles

- Utilizado para encontrar padrões inesperados nos dados

- Inerentemente é um problema não definido claramente

- Como agrupar os animais abaixo?



Mamífero? Ovíparo? Ambos?

O Problema da Escala (A Cilada Euclidiana)

Desafio Geométrico: Algoritmos usam distância em espaço n-dimensional.

Impacto das Grandezas: Atributos com escalas discrepantes dominam o cálculo.

Exemplo Clássico: Idade (18 a 80 anos) vs Renda Mensal (R\$ 2.000 a R\$ 50.000).

Resultado do Erro: Renda esmaga Idade. Idade fica estatisticamente irrelevante.

Conclusão: Normalizar antes de calcular distância.



NORMALIZAÇÃO DE ATRIBUTOS

Profª Drª Denise Tsunoda

2026

Normalização de Atributos antes do K-Means

- O K-Means agrupa dados com base em distâncias
- Se um atributo tem valores muito maiores, ele "domina" o resultado
- **Normalizar = 'colocar todos na mesma régua'**
- Exemplo: Idade $(20-60)^2$ x Renda $(1.000-10.000)^2$
- → A renda tem muito mais influência na distância!

O problema da escala

- • Se o K-Means utilizar distâncias euclidianas
- • Escalas diferentes distorcem os grupos

Pessoa	Idade	Renda (R\$)
A	25	2000
B	45	10000

- Sem normalizar: renda domina
- Com normalização: cada variável tem o mesmo peso

O que é normalização

- Normalizar = **ajustar valores para uma mesma faixa comparável**

Método	Intervalo	Indicado para
Escalonamento logarítmico	0 a 1	Dados assimétricos
Min–Max	0 a 1	Dados sem outliers
Valor máximo	0 a 1	Casos simples

Escalonamento logarítmico

Usado quando há **grande variação** nos dados (ordens de magnitude diferentes).

A compressão logarítmica reduz o impacto de valores muito altos.

$$x' = \frac{\log(x + 1)}{\log(x_{max} + 1)}$$

◆ Usado em dados financeiros, contagens, populações, etc.

◆ O `+1` evita $\log(0)$.

◆ Produz valores entre 0 e 1.

$$x' = \frac{\log(10 + 1)}{\log(1000 + 1)} = \frac{1,0414}{3,0004} \cong 0,35$$

Valor original (x)	$\log_{10}(x + 1)$	$\log_{10}(1001)$	Normalizado (x')
1	0,3010	3,0004	0,10
10	1,0414	3,0004	0,35
100	2,0043	3,0004	0,67
1000	3,0004	3,0004	1,00

Solução: Normalização Min-Max

Objetivo: Trazer todas as variáveis para mesma escala, peso justo no cálculo.

Mecânica: Escalonamento linear para intervalo [0, 1].

Fórmula:

$$X_{norm} = \frac{(X - X_{min})}{(X_{max} - X_{min})}$$

Interpretação:

- Menor valor da base $\rightarrow 0$
- Maior valor da base $\rightarrow 1$
- Demais valores distribuídos proporcionalmente


Normalização Min-Max

- Fórmula:

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Idade	Normalizada
20	0
40	0,5
60	1


$$X' = \frac{(20 - 20)}{(60 - 20)} = 0$$


$$X' = \frac{(40 - 20)}{(60 - 20)} = 0,5$$


$$X' = \frac{(60 - 20)}{(60 - 20)} = 1$$

-  Escala de 0 a 1
-  Sensível a valores extremos

Valor máximo = 1

- Fórmula:

$$X' = \frac{X}{X_{max}}$$

Idade	Normalizada
20	0,33
40	0,67
60	1


$$X' = \frac{(20)}{(60)} = 0,33$$


$$X' = \frac{(40)}{(60)} = 0,67$$


$$X' = \frac{(60)}{(60)} = 1$$

-  Simples e intuitiva
-  Ótima para demonstrações
-  Se houver valor muito alto, achata os demais

O Conceito de Distância Euclidiana

Métrica Padrão: Distância em linha reta entre dois pontos.

Para 2 dimensões: $d(P,Q) = \sqrt{(p_1-q_1)^2 + (p_2-q_2)^2}$

Para n dimensões: $d(x,y) = \sqrt{\sum (x_i - y_i)^2}$

Premissa Crítica: Atributos devem ser numéricos e normalizados.

Outras Métricas de Distância

Manhattan (City Block): Soma das diferenças absolutas.

$$d(x,y) = \sum |x_i - y_i|$$

Simula caminho por quarteirões em uma cidade.

Chebyshev: Maior diferença absoluta entre dimensões.

$$d(x,y) = \max |x_i - y_i|$$

Distância máxima em um único eixo.

O Algoritmo K-Means (Particionamento)

Conceito Central: Divide dados em K grupos definidos a priori pelo usuário.

Natureza Centróide: Cada cluster é representado pela média dos pontos do grupo.

Processo Heurístico: Algoritmo iterativo que minimiza variância interna.
(Soma dos Quadrados dos Erros - SSE)

O Fluxo de Execução do K-Means

Passo 1: Escolha o número K de grupos desejados.

Passo 2: Inicialize K centróides aleatórios na base.

Passo 3 (Atribuição): Calcule distância de cada ponto aos K centróides. Aloque ao mais próximo.

Passo 4 (Atualização): Recalcule centróide = média dos pontos atribuídos.


Passo 5 (Convergência): Repita 3 e 4 até centróides pararem de mudar.

k -Médias - Algoritmo


- Passo 1: Os primeiros k centros dos aglomerados / agrupamentos são escolhidos aleatoriamente
- Passo 2: Cada objeto é atribuído ao grupo associado com o centro mais próximo (rotulação)
- Passo 3: Calcule um novo centro para cada grupo (média dos valores de todos os objetos - centróide)
- Passo 4: Repita Passo2 (com os novos centros) e Passo3 até que não haja mudança nos centros (ou outro critério de parada seja atingido)

k -Médias: Exemplo

As figuras abaixo, representam a aplicação dos dois primeiros passos do algoritmo k -médias em um arquivo com 20 dados com dois atributos contínuos, considerando-se um número de médias $k = 3$.



Inicialização das médias




Atribuição dos rótulos


k -Médias: Exemplo (cont)

Após o passo de rotulação, as médias são atualizadas considerando-se a nova configuração dos agrupamentos.

Após as médias serem atualizadas, os rótulos são atualizados pela distância às novas médias.



Atualização das médias



Nova atribuição de rótulos e
atualização das médias

Nosso Exemplo Âncora (Dataset de Teste)

Para entender as iterações, usaremos 6 pontos:

Ponto A: $X=1, Y=1$


Ponto B: $X=2, Y=1$

Ponto C: $X=1, Y=2$

Ponto D: $X=5, Y=4$

Ponto E: $X=5, Y=5$

Ponto F: $X=6, Y=5$



Objetivo: Separar em $K=2$ grupos visualmente óbvios.

Visualizando os Pontos no Plano

No plano cartesiano:

Grupo 1 natural: $A(1,1)$, $B(2,1)$, $C(1,2)$ → canto inferior esquerdo

Grupo 2 natural: $D(5,4)$, $E(5,5)$, $F(6,5)$ → canto superior direito

Espaço vazio entre grupos mostra boa separação.

K-Means deve encontrar esses 2 clusters automaticamente.

Iteração 1 - Atribuição Inicial Detalhada

Centróides iniciais: A(1,1) e F(6,5). K=2

Calculando distâncias para cada ponto:

- B(2,1): $d(B,A)=\sqrt{[(2-1)^2+(1-1)^2]}=\sqrt{1}=1,00$ | $d(B,F)=\sqrt{[(2-6)^2+(1-5)^2]}=\sqrt{32}=5,66 \rightarrow B \rightarrow A$
- C(1,2): $d(C,A)=\sqrt{[(1-1)^2+(2-1)^2]}=\sqrt{1}=1,00$ | $d(C,F)=\sqrt{[(1-6)^2+(2-5)^2]}=\sqrt{34}=5,83 \rightarrow C \rightarrow A$
- D(5,4): $d(D,A)=\sqrt{[(5-1)^2+(4-1)^2]}=\sqrt{25}=5,00$ | $d(D,F)=\sqrt{[(5-6)^2+(4-5)^2]}=\sqrt{2}=1,41 \rightarrow D \rightarrow F$
- E(5,5): $d(E,A)=5,66$, $d(E,F)=1,00 \rightarrow E \rightarrow F$

Resultado: Cluster 1 = {A,B,C} | Cluster 2 = {D,E,F}

Iteração 1 - Atualização dos Centróides

Calculando novas médias:

Novo Centróide 1 (de A,B,C):

$$X = (1+2+1)/3 = 4/3 = 1,33$$

$$Y = (1+1+2)/3 = 4/3 = 1,33$$

Coordenadas: (1,33; 1,33)


Novo Centróide 2 (de D,E,F):

$$X = (5+5+6)/3 = 16/3 = 5,33$$

$$Y = (4+5+5)/3 = 14/3 = 4,67$$

Coordenadas: (5,33; 4,67)

Plotagem de pontos



Iteração 2 - Recálculo e Estabilização

Verificação: Recalculamos distância de todos aos novos centróides.

Resultado: Nenhum ponto troca de grupo.

- A: $d=0,47$ de C1, $d=5,56$ de C2 $\rightarrow$ fica no C1
- D: $d=5,56$ de C1, $d=0,47$ de C2 $\rightarrow$ fica no C2

Convergência: Clusters idênticos à iteração anterior.

Algoritmo encerra. Grupos finais: {A,B,C} e {D,E,F}

Calculando a SSE na Prática

SSE = Soma dos Quadrados dos Erros = soma das distâncias² ao centróide

Para K=2, C1=(1,33;1,33), C2=(5,33;4,67):

- $d(A,C1)^2 = (1-1,33)^2 + (1-1,33)^2 = 0,22$
- $d(B,C1)^2 = (2-1,33)^2 + (1-1,33)^2 = 0,56$
- $d(C,C1)^2 = (1-1,33)^2 + (2-1,33)^2 = 0,56$
- $d(D,C2)^2 = (5-5,33)^2 + (4-4,67)^2 = 0,56$
- $d(E,C2)^2 = 0,22, d(F,C2)^2 = 0,56$

SSE Total = 0,22+0,56+0,56+0,56+0,22+0,56 = 2,67

Como Escolher o K Ideal? (Método do Cotovelo)

Dilema: Como saber K se não temos rótulo?

Método: Rode K-Means para K=1 até 10. Calcule SSE de cada.


Plote: K no eixo X, SSE no eixo Y.

Dados A-F:

K=1→43,33, K=2→2,67, K=3→1,33, K=4→0,67, K=5→0,33, K=6→0,00

Cotovelo: Queda brusca de 43,33 pra 2,67, depois estabiliza.

Decisão: K=2 é o ideal. Confirma os 2 grupos visuais.




O fato de em **K=6** o SSE chegar a 0 indica que cada ponto virou praticamente seu próprio cluster, o que perde sentido analítico. → OVERFITTING

Método do Cotovelo - Passo a Passo

1. Execute K-Means para $K=1,2,3,\dots,10$
2. Para cada K , calcule SSE = soma das distâncias² de cada ponto ao seu centróide
3. Plote gráfico: eixo $X=K$, eixo $Y=SSE$
4. Identifique ponto de inflexão: onde curva deixa de cair drasticamente

Esse ponto é o K ideal. Adicionar mais clusters quase não reduz SSE .

Exemplificando $k = 3$



Interpretando o Cotovelo

Por que SSE sempre cai? Mais clusters = pontos mais próximos dos centróides.

K=6 com 6 pontos: SSE=0, cada ponto é seu próprio centróide.

Mas K=6 é inútil: queremos agrupar, não isolar.

Cotovelo equilibra: SSE baixo + número baixo de clusters.

Dados A-F: Redução de 93.8% em K=2. Depois, ganho marginal.

Limitações do K-Means

1. Sensibilidade à Inicialização: Centróides iniciais ruins → mínimo local ruim.
2. Formato dos Grupos: Assume clusters esféricos. Falha com formatos alongados.
3. Outliers: Valores extremos deslocam centróide para longe do centro real.

Mitigação: Rodar múltiplas vezes, K-Means++, normalizar dados.


K-Means vs K-Means++

Exemplo com 6 pontos e $K = 2$

K-MEANS (inicialização aleatória)


1. Escolha inicial dos centróides (aleatória)

Dois centróides são escolhidos aleatoriamente (podem ficar próximos)




2. Atribuição inicial dos pontos

Cada ponto é atribuído ao centróide mais próximo.



3. Recalcula centróides e repete até convergir

Pode exigir mais iterações e, às vezes, levar a soluções piores.




K-MEANS (aleatório):

- Pode começar com centróides ruins (muito próximos).
- Convergência mais lenta.
- Maior chance de mínimos locais (soluções piores).

K-MEANS++ (inicialização inteligente)


1. Escolha do primeiro centróide (aleatória)

Um ponto é escolhido aleatoriamente como primeiro centróide.




2. Escolha do próximo centróide (probabilística)

Os pontos mais distantes do centróide escolhido têm maior probabilidade de serem selecionados.



3. Continua o K-Means normalmente

Com centróides bem espalhados, o algoritmo converge rapidamente para uma boa solução.



K-MEANS++:

- Escolhe centróides iniciais espalhados.
- Convergência mais rápida.
- Menor chance de mínimos locais, melhor qualidade final.

Temos outros métodos de agrupamento:

a) agrupamento hierárquico

b) DBSCAN

c) ...

mas eles seguem lógicas matemáticas diferentes e exigiriam outra aula para serem tratados adequadamente.



Execução no Excel

EXEMPLO

Para a tabela abaixo, crie dois grupos distintos com os pontos A e F como centróides e função de distância euclidiana quadrática. Utilizar o algoritmo k-means com 2 iterações.


Pontos	X	Y
A	1	1
B	1	4
C	3	2
D	2	2
E	1	3
F	2	1



Execução no Weka

SimpleKMeans no Weka

- ➔ Importar o conjunto de dados (ARFF/CSV).
- ⚙ Configurar o algoritmo **SimpleKMeans**.
- ↻ Comparar a saída automática com a sua execução manual.
- 📈 Observar o número de iterações e o erro final (SSE).



Clusterer

Choose

SimpleKMeans -init 0 -max-candidates 100 -periodic-pruning 10000 -min-density 2.0 -t1 -1.25 -t2 -1.0 -N 2 -A "weka.core.EuclideanDistance -R first-last" -I 500 -num-slots 1

Cluster mode

☒ Use training set☐ Supplied test set

Set...

☐ Percentage split

%

66

☐ Classes to clusters evaluation

(Nom) class

☒ Store clusters for visualization


Ignore attributes

Start

Stop

Result list (right-click for options)

Clusterer output



Fechamento do Bloco Teórico I

'Se vocês não limparem a escala dos atributos antes, K-Means pode produzir agrupamentos distorcidos no relatório. Protejam seus modelos normalizando!'

Checklist Para Estudar Sozinho:

- 1. Refazer no papel a tabela de distâncias do Slide 28**
2. Plotar os pontos A-F no plano e desenhar centróides se movendo
3. Conferir se sua SSE bateu com 2,67 para $K=2$

Próxima Parada: Vamos testar nas ferramentas!

Aprendizado de Máquina

K-MEANS NA PRÁTICA

Atividade Prática em Grupo: Do Cálculo Manual à Execução no Weka



Objetivos e Dinâmica

Entendendo os fundamentos do agrupamento por centróides

Objetivos da Atividade



Cálculos

Dominar o cálculo de distâncias euclidianas e atualização de centróides.



Clusters

Compreender a formação de grupos e o impacto do valor de K.



Análise

Interpretar resultados e avaliar a influência da normalização.

| Organização da Dinâmica



Grupos



Atividade realizada inteiramente durante a aula.



Foco em discussão e socialização coletiva.



Sem entrega de relatório formal.

Configurações por Grupo (Abas)

Cada grupo deve escolher uma aba e utilizar os parâmetros iniciais abaixo:

Cenário (Aba)	Contexto	K	Centróides Iniciais (X, Y)
Aba 1	Varejo	2	C1(50, 2) C2(450, 8)
Aba 2	Indústria	2	C1(40, 15) C2(90, 80)
Aba 3	Real Estate	3	C1(50, 2) C2(120, 8) C3(210, 4)
Aba 4	Esporte	2	C1(32, 8) C2(23, 12)
Aba 5	Crédito	2	C1(30, 5) C2(100, 80)
Aba 6	App	3	C1(10, 1) C2(130, 18) C3(150, 2)



Simulação no Excel **Visualização Weka**

O "Coração" do Algoritmo Passo a Passo

Fluxo de Simulação Guiada do K-Means

-  **Plotagem:** Inserir os pontos e centróides iniciais no plano cartesiano.
-  **Distância:** Calcular a distância euclidiana de cada ponto aos centróides.
-  **Associação:** Vincular cada ponto ao centróide mais próximo.
-  **Atualização:** Recalcular a média dos pontos para definir o novo centróide.
-  **Iteração:** Repetir o processo até a convergência dos grupos.
-  **SSE:** Calcular e interpretar o SSE.
-  **WEKA:** Carregue a base no Weka (CSV) e veja como fica a distribuição espacial.

A Lógica Euclidiana

O K-Means busca minimizar a inércia intra-classe. Para isso, utilizamos a métrica de distância para definir fronteiras:

$$d(p, q) = \sqrt{\sum_{i=1}^n (q_i - p_i)^2}$$

Lembrem: Atributos em escalas diferentes podem dominar o cálculo se não forem normalizados!



Encerramento e Quiz

Preparem-se para testar seus conhecimentos
sobre:

- SSE • Centróides • Normalização • Método do Cotovelo